

Trouver des sujets vidéos tech — scraper 100 sites/jour SANS token

Détecter chaque jour les sujets tech qui montent en scannant **100+ sources**, sans dépenser un seul token d'IA (aucun appel LLM) et sans API payante. Prompt de build en \$5.

Principe : « sans token » = zéro LLM

Détection 100 % déterministe/offline (fréquence, stats, NLP classique). Aucun appel modèle → coût 0. Uniquement des flux **gratuits sans clé** (RSS/Atom, JSON publics). L'écriture Notion utilise la clé d'intégration Notion (gratuite), pas un token d'IA.

1. Les sources (100+), gratuites & sans clé

A. Agrégateurs sociaux (heat) : Hacker News (Firebase `topstories.json` + Algolia `search_by_date`) · Reddit `r/<sub>/top.json?t=day` · Lobsters RSS · Product Hunt feed · Dev.to feed · GitHub Trending (miroir RSS) · Journal du Hacker RSS. **B. Trends** : Google Trends Daily RSS `trends.google.com/trending/rss?geo=FR` (+ US). **C. Presse tech (RSS)** : Verge, TechCrunch (full-text), Ars Technica, Wired, Engadget, Gizmodo, TechRadar, ZDNet, CNET, Mashable, VentureBeat, TNW, Techmeme, MIT Tech Review, IEEE Spectrum, The Register, Slashdot, Digital Trends, Tom's Hardware, 9to5Mac/Google, MacRumors, Android Police. **D. IA** : Google AI, OpenAI, Anthropic, DeepMind, Hugging Face, MarkTechPost, VentureBeat AI, arXiv `cs.AI/cs.LG` RSS, Papers with Code. **E. Startups/VC** : TechCrunch, Sifted, Crunchbase News, CB Insights, a16z, Indie Hackers. **F. Dev** : GitHub Blog, Stack Overflow Blog, InfoQ, Hacker Noon, CSS-Tricks, Smashing, freeCodeCamp. **G. Français** : Numerama, Frandroid, 01net, Les Numériques, Next, Journal du Geek, Presse-citron, Siècle Digital, Usine Digitale, Maddyness, BFM Tech. **H. Science/futur** : New Scientist, Quanta, Nature News, ScienceAlert, Interesting Engineering.

 Atteindre 100+ : importer les OPML **Feedspot « Top 80 Tech News »** + gists GitHub de flux. Un `sources.opml` versionné = ta liste vivante.

2. Le scoring SANS LLM (déterministe)

Pour chaque item (titre + résumé) des dernières 24-36 h : 1. **Extraction** offline : spaCy NER + noun phrases ; YAKE/RAKE/TF-IDF pour les n-grammes. 2. **Clustering** des quasi-doublons en « sujets » : TF-IDF + cosinus, ou MinHash/SimHash. 3. **Score de sujet** = corroboration (nb de sources distinctes) + vélocité (fréquence 24h vs baseline 7j) + chaleur sociale (points HN, upvotes Reddit, votes PH) + bonus Google Trends + décroissance de récence. 4. **Filtre DA** (règles, pas d'IA) : garder les piliers (IA, grandes boîtes, bourse/IPO, code, innovation) ; **blacklist** de mots pour exclure resell/sneakers/Vinted.



3. Titres candidats SANS LLM (templates R9)

Remplir des moules de questions avec l'entité détectée : « Pourquoi {X} {événement} ? » · « Comment {X} a {résultat} ? » · « {X} : ce que personne ne dit ». À polir à la main ensuite (0 token).



4. Sortie quotidienne

Top 10-15 sujets classés par score, chacun avec titre(s), score + justification, 2-4 liens, pilier + style reco. Écriture dans Notion (base Scripts, Statut=Idée, ou base « Radar »). Archive `out/radar-YYYY-MM-DD.md` . Cron quotidien.



5. PROMPT à coller dans Claude Code

Construis-moi un outil CLI Python "radar-tech" qui, chaque matin, détecte les sujets tech MONTENT en scannant 100+ sources d'actu, SANS AUCUN appel LLM (coût token = 0) et sans AP payante. Il propose des idées de vidéos dans Notion, calibrées sur ma DA.

Contrainte absolue : ZERO TOKEN

- Aucune requête à un modèle d'IA. Détection déterministe/offline (stats + NLP classique) Uniquement des flux GRATUITS SANS CLÉ (RSS/Atom, JSON publics).
- L'écriture Notion utilise la clé d'intégration Notion (gratuite), pas un modèle.

Sources (fichier sources.opml versionné, 100+)

- Sociaux/heat : HN (Firebase topstories + Algolia search_by_date), Reddit r/<sub>/top.js (technology, artificial, singularity, Futurology, programming, gadgets, SaaS, startups) Lobsters RSS, Product Hunt feed, Dev.to feed, GitHub Trending (miroir RSS), Journal du
- Trends : Google Trends Daily RSS (geo=FR et geo=US).
- Presse tech (RSS) : Verge, TechCrunch, Ars, Wired, Engadget, TechRadar, ZDNet, VentureB
- IA : Google AI, OpenAI, Anthropic, DeepMind, Hugging Face, MarkTechPost, arXiv cs.AI/cs
- FR : Numerama, Frandroid, 01net, Les Numériques, Next, Journal du Geek, Siècle Digital, Usine Digitale, Maddyness.
- Fournis un sources.opml de départ (>= 100 flux) + un script d'ajout via OPML Feedsport/g

Pipeline quotidien

1. Ingestion : feedparser sur tous les flux + fetch JSON HN/Reddit/PH. Chaque source dans try/except isolé (une source down ne casse jamais le run), timeouts, retries backoff.
2. Normalisation : titre + résumé + source + date + url ; dedup par url et similarité de
3. Extraction offline : spaCy NER + noun_chunks, YAKE/RAKE/TF-IDF pour les n-grammes.
4. Clustering : TF-IDF + cosinus (ou MinHash) pour regrouper les articles en "sujets".
5. Scoring déterministe : corroboration (nb sources) + vélocité (24h vs baseline 7j du st + chaleur sociale (points HN, upvotes Reddit, votes PH) + bonus Google Trends + récénc Pondérations dans config.yaml.
6. Filtre DA (règles) : garder piliers (IA, grandes boîtes, bourse/IP0, code, innovation) blacklist pour EXCLUDE resell/sneakers/Vinted.
7. Titres candidats SANS LLM : templates de questions (moules R9) remplis avec l'entité d
8. Sortie : top 10-15 sujets triés ; titre(s), score + justification, 2-4 liens, pilier + Écrire dans Notion (base Scripts, Statut=Idée, ou base "Radar") via l'API Notion. Archive out/radar-YYYY-MM-DD.md. Résumé console.

Technique

Python 3.11+, deps : feedparser, requests, scikit-learn, spacy (fr+en), yake, datasketch, pyyaml, python-dotenv, notion-client. AUCUNE lib LLM. Cache 24-36h, state.json (baseline titres déjà proposés = idempotence). README + tests (parsing, dedup, scoring, blacklist). Cron : 0 7 * * * cd /chemin/radar-tech && python3 run.py >> out/cron.log 2>&1

Commence par l'arborescence + sources.opml + le plan, puis code, teste, et fais un dry-run (sans écrire dans Notion) que je validerai avant d'activer l'écriture.

Note « 0 token » vs qualité des titres

Le pipeline détecte et classe sans coût. Les titres par templates sont bruts : soit tu les polis à la main (0 coût), soit tu ajoutes **en option** une seule passe IA sur les 10 sujets finaux (coût minime). Le radar reste à token = 0.

Sources

Feedspot (Top 80 Tech RSS) · gists GitHub de flux · HN API/Algolia · Google Trends RSS · Reddit .json · NLP sans LLM (TF-IDF, RAKE/YAKE, spaCy NER, MinHash).